基于多源管网数据的模型构建与性能比较研究

目录

摘要 1

1.前言 2

2.数据与问题说明 3

2.1 数据说明 3

2.2 问题定义 4

3.方法（模型构建） 5

3.1 数据预处理 5

3.2 液位预测模型 7

3.3 异常识别方法 8

3.4 多变量预测模型 9

3.5 原因识别方法 10

4.算法结果与准确性分析 11

4.1 液位预测准确性 11

4.2 异常识别结果 12

4.3 多变量预测准确性 13

4.4 原因识别结果 14

5.算法效率与可靠性分析 16

6.模型性能比较与讨论 17

7.结论 18

References 19

摘要

随着城市管网监测数据采集频率和维度的提升，如何基于多源时间序列数据开展准确预测、异常识别和成因分析，成为城市水系统管理中的重要问题。

本文基于管网液位、气象及多变量观测数据，构建并比较了多种时间序列模型和机器学习模型，从预测准确性、计算效率和结果可靠性等方面对模型性能进行了评估。

通过实验发现，在液位预测和多变量预测任务上，基于梯度提升的模型均要比传统的时间序列模型、线性模型好很多；且该类模型针对稳定性及训练效率都有更好的表现。另外，结合模型解释发现，基于历史昼夜节律特征的方法，对于非正常工作状态的异常数据有着很好的区分能力。此外，结合模型解释分析结果可知，在高值阶段，各观测变量最主要的影响采集点是稳定的，并且取值情况也是一致的。

研究表明，将预测、异常识别与成因分析相结合的梯度提升方法，能够为高频、多变量的管网监测与管理提供有效的数据驱动支持。

1.前言

随着城市化建设的不断发展，城市管网系统的排水功能，防洪功能与环保功能越来越强，在整个城市水系的规划建设中占有很重要的地位。城市管网运行状态受多方面的影响：包括降雨变化、来水负荷等外力因素影响和系统自身的结构特点所引起的内部原因，而液位等其他观测变量值的变化容易出现较大波动，液位等观测变量值的剧烈变化往往代表着管网运行状态已经产生改变，并且带来了可能的风险因素，所以必须要利用历史监测数据，准确定位系统目前的运行情况并做出预测，同时还要尽早发现并查清出现问题的原因。

近来，随着传感器技术的发展和数据采集手段的进步，可以获得管网系统内的高频率和多源时间序列数据，这为管网系统的精细化建模提供了基础，也使传统的方法越来越不能满足要求。而一些以时间作为索引维度的分钟级高频数据往往表现为数据存在明显的周期性和波动性；对于长序列和高维外生变量来说，使用传统的时序模型分析效率偏低且影响结果准确性；同时，在现实问题场景中往往还包含了多变量观测数据间的非线性关系和潜在的交互关系，单一线性模型无法反映其内在联系。

得益于机器学习技术的应用和发展，在管网数据相关方面已陆续开展了大量有关预测或识别的工作。其中基于树结构集成模型具备较强非线性建模能力及较好计算速度等优点，并且随着预测模型可解释性的增强，有助于通过联合使用预测模型和解释模型加深对模型预测结果的解读以及辨别可能影响因素。因此对于工程应用来说，还需探究如何平衡模型精度、计算速度及结果解释性的关系。

根据上文背景，本文主要围绕管网液位和多变量观测数据展开相关的系统性数据建模及分析工作。主要研究的内容有：第一、以管网液位的历史数据及气象等外生变量为出发点，分别采用传统的时间序列模型与机器学习模型对未来的液位进行预测，并对比不同模型之间的预测效果以及计算效率；第二、参考之前正常时期液位的昼夜规律，运用现有的相关算法和技术，检测并判断下一步可能出现的异常，统计这些异常行为发生的周期性或间歇性；第三、针对多变量观测数据，通过构建不同的机器学习

模型来完成对应的预测任务，进而从各方面对比模型的整体性能；第四、通过对预测结果引入模型解释方法得到某时刻观测值达到高值的可能原因，识别出各个影响观测变量的重要变量。

建立兼顾预测效果、计算速度及结果可解释性的管网模型建模流程，在此基础上将用于实时高维管道监测的实际管网数据进行建模分析，以期为实际管网模型的构建、分析、预警等工作提供参考。研究成果有助于更清晰地掌握管网系统的运行特性，从而为进一步开展异常预警与辅助决策提供依据。

2.数据与问题说明

2.1 数据说明

本文所使用的数据主要包括管网液位监测数据、气象数据以及多点采集的流量与负载观测数据，分别来源于 sta.csv、met.csv 和 inflow_loading_obs.xlsx 文件。各数据集在时间分辨率和采样方式上保持一致，能够满足后续建模与分析的需要。

（1）管网液位数据（sta.csv）

sta. csv 文件是管网监测点在不同时间的运行状况信息数据，本文的重点是研究 WaterLevel 这一变量（以 m 为单位），其所代表的“液位”是指管网中测得的水位，而非管段、控制设备内的液位、流速（Velocity）、流场、流量（Flow）等其它水力学相关参数。

对于液位预测任务，液位数据是历史输入变量和预测目标变量；对于异常识别任务，液位数据刻画了管网运行昼夜节律特点，同时作为主要异常检测对象。

（2）气象数据（met.csv）

m t. csv 文件包含了和管网运行有关的气象观测数据，主要包括降雨量（Rainfall）等等；气象数据与液位数据按照时间进行对齐，是为了从外部环境的角度分析影响到管网液位变化的因素。

本例中，气象数据主要有两个方面的用途：一是对于液位预测任务来说，气象变量作为外生输入信息，用来辅助模型刻画液位变化和降雨之间的关系；二是针对异常识别任务而言，气象数据可以区分降雨导致的正常的液位波动和不符合日常运行规律的异常行为。

（3）多点流量与负载数据（inflow_loading_obs.xlsx）

inflow_loading_obs. xlsx 中包括不同站点记录下来的不同采样点的 infow、loading 以及 obs 的数据，其中 infow 和 loading 是一个采样点的两种输入量测值，obs 是相对应的输出响应值。

本文在多变量预测任务中将 inflow 和 loading 的有关变量作为输入，针对所有 obs 进行数值预测；原因识别任务就是当某一个 obs 的值相对偏高的时候，通过找出 inflow－loading 组合对模型输出的最大贡献项来判断导致观测值高估的根源所在。

（4）时间范围与数据划分说明

考虑到每种分析任务需要建立不同的模型，本文基于时间维度的不同将原始数据进行切分，液位预测任务采用 2022 年 10 月 1 日至 2022 年 11 月 11 日之间的液位数据做模型输入并预测从 2022 年 11 月 11 日至 2022 年 12 月 1 日之间的液位变化；异常识别任务取 2022 年 10 月 20 日至 2022 年 11 月 10 日的数据作为正常昼夜节律的参考区间，在 2023 年 1 月 1 日到 2023 年 2 月 1 日期间的数据做异常检测。多变量预测与原因识别任务以 inflow、loading 以及 obs 数据为出发点。多变量预测与原因识别任务使用的全部数据为 inflow、loading、obs,其余两个任务所需的数据分别为前 30 天的数据和前 70 天的数据。

（5）补充说明

需要指出的是，本文在数据说明部分仅介绍原始观测变量。具体的特征构造方法和变量变换过程，将在后续方法章节中进行详细说明。

2.2 问题定义

基于前述数据来源，本文围绕管网运行数据的分析与建模需求，设计并研究了四类问题。这四类问题分别对应不同的建模目标，同时用于评估模型在不同任务场景下的表现。

（1）基于液位与气象数据的短期液位预测问题

一部分主要是管网液位的短期预测能力，使用了 sta. csv 和 met. csv 文件中的相关管网液位及气象数据作为模型输入，取用 2022 年 10 月 1 日～2022 年 11 月 11 日的数据构建模型并预测 2022 年 11 月 11 日至 2022 年 12 月 1 日之间管网液位变化情况。

对此问题建立本章分别使用传统时间序列模型以及机器学习/深度学习模型两种预测方法。其中以时间为准则确定选择两类预测模型中何种类型，要求每种方式都完成建模任务；将基于不同模型的预测结果进行对比分析，在预测精度、计算速度、结果稳定程度等维度来判断不同的模型适合不同液位预测场景的程度。

（2）基于昼夜节律特征的液位异常识别问题

除了前面讨论过的有关二元网格的大部分问题外，本节关注的都是管网液位异常行为的检测问题。本文使用了 2022 年 10 月 20 日-2022 年 11 月 10 日液位数据作为正常运行时期参考值，从数据中抽取出了管网液位的昼夜节律特征，并将该时期内同期的降雨量数据放入进考虑范围，得到正常运行模式。

再进行 2023 年 1 月 1 日至 2023 年 2 月 1 日的液位数据的统计分析，发现存在数据不能满足昼夜节律规律的现象，并分析其原因。为防止将白天的超低液位与夜间降雨所导致的低液位相混淆，在本文中，凡在忽略降雨时仍能确定为异常行为的低液位皆属于所指异常行为范围。

（3）基于多变量输入的 obs 数值预测问题

第三类问题关注多变量条件下的预测任务。本文基于 inflow_loading_obs.xlsx 文件中的数据，以 inflow 和 loading 相关变量作为输入，以各 obs 变量作为预测目标，构建至少两类不同的机器学习模型，对 obs 数值进行预测。

通过比较不同机器学习模型的预测结果，从预测精度、计算效率和模型稳定性等方面，分析各类模型在多变量预测任务中的表现差异。

（4）obs 异常高值的原因识别问题

除第三类问题建模外，第四类问题更关心 obs 异常高值的成因分析，在任意 obs 值过高时，基于输入变量—输出变量的映射关系，挖掘造成其过高的最有可能的 inflow-loading 组合是什么。

由于每组 inflow 与 loading 数据均来源于同一采集点，本文通过分析不同采集点对应输入变量对模型输出的影响程度，判断 obs 异常高值更可能由哪一采集点的 inflow 与 loading 变化所引起，从而提升模型结果的可解释性和实际应用价值。

（5）总体说明

需要强调的是，尽管上述四类问题在建模目标上有所不同，但均以模型性能评估为核心。本文通过在不同任务场景下对多种模型进行对比分析，系统评估其在预测准确性、计算效率和结果可靠性等方面的表现。

3.方法（模型构建）

3.1 数据预处理

在模型构建之前，本文对原始数据进行了必要的数据预处理，以保证数据质量、时间一致性以及不同模型之间性能比较的公平性。本文使用的数据包括管网液位数据、气象数据以及多点采集的 inflow、loading 和 obs 数据。不同数据源的预处理过程如下所述。

（1）管网液位与气象数据预处理（sta.csv 与 met.csv）

首先，首先读取管网液位数据（sta. csv）与气象数据（met. csv），将两者文件里面的时间字段都转换成同一种时间格式，再利用相关函数将时间戳标准化。<!--{img:0}-->

然后按照时间的先后顺序进行液位数据、气象数据的排序，确保时间序列按实际发生时序排序，防止数据顺序出错导致模型训练结果或者预测结果出错；结合液位预测和异常识别的任务需求，在此把选取相应时间范围的数据子集开展进一步分析。

为保证数据质量，在数据预处理阶段对液位变量及气象变量开展缺值检验。通过计算各个变量在时间段内出现的缺值个数，可得该组数据不存在大量缺值及明显的异常值，因此不用对变量采取特殊的处理方式以保证模型性能比较结果一致。

本阶段以时间为索引，将液位与气象数据进行了融合，并形成了一致的数据集。因此，在任一时刻，液位观测值均对应某一时刻的气象情况，这样可以使模型在预测液位变化时考虑时间序列本身的特征的同时也考虑到了环境因素的影响。

需要指出的是，在数据预处理阶段没有对液位和气象原始观测值作额外的平滑、滤波、人工修正等处理，尽量保留原始数据的变化特征，以免引起人为干预而改变模型评估的结果。

（2）inflow、loading 与 obs 数据预处理（inflow_loading_obs.xlsx）

为进行多变量预测及原因分析，在文中使用了 inflow_loading_obs. xlsx 表的数据，首先导入原始数据，再根据时间变量 jday 升序排列，保证多变量的时间序列是按照时间轴发展的。

接着依据数据列的命名规则来给各个变量进行分类，把 inflow1-8 和 loading1-8 作为一个模型的输入变量，在这部分共包含 16 列；把 obs1-12 列为预测目标变量，在这部分共包含 12 列。这样的分组方式可以让模型输入和输出有明确的语义意义，也能做到多变量分组后的结果易于对比分析。

本文还对 inflow、loading 及 obs 变量进行了缺失值检查，通过对上述三个变量的缺失情况进行统计发现各变量中无明显缺失值出现，且总体上数据质量较高。因此，在后续的建模过程中直接用实际观测数据作为输入输出值，不考虑利用插值、补齐等方式处理后的数据，并以此来保证后续模型对比结果的准确。

（3）预处理一致性说明

这里要说明一下，本文的数据预处理只是将各个指标的时间顺序排序，再将不同的变量分开成不同的数据集，并且时间对齐之后，再检查了缺失值问题。除上述步骤外，没有做额外的特征转换或假设，也即是所有模型都基于相同的数据集进行训练及评估，以保证同一种模型或者算法的预测准确率、计算时间以及结果稳定性可以进行对比，也即做到公平比较。

具体的特征构造方法、滞后变量的生成、标准化处理步骤将在后面的模型介绍章节中详细阐述。

3.2 液位预测模型

关于管网液位的短期预测，将从 sta. csv 中的液位数据和 met. csv 中的气象数据出发，分别采用两种模型，SARIMAX（传统时间序列模型）与 LightGBM（基于梯度提升树的机器学习模型），利用数据对模型进行训练，并使用训练后的模型对该段时间内的管网液位做预测，模型训练时间为 2022-10-01～2022-11-11，预测目标时间为 2022-11-11～2022-12-01 管网液位的变化情况。

（1）基于 Fourier－SARIMAX 的传统时间序列模型

为了表征液位序列在分钟尺度上的周期性变化规律，基于 SARIMAX（Seasonal Autoregressive Integrated Moving Average with eXogenous variables）模型作为传统的时序预测模型对时间序列开展预测研究，该模型可以表征液位序列的自相关结构，加入气象要素作为外生变量，可以兼顾考虑历史液位变化与外界环境影响。

在前期模型探索时，也曾尝试过将分钟级季节性项直接带入 SARIMAX 模型中以体现液位的日周期变化。但由于分钟级的季节长度过长，实际运行时计算量较大，模型训练用时较长，在此情况下不利于后续多模型对比分析，所以在保持一定模型表达能力下采用 Fourier 系列特征来近似刻画液位的日周期变化，取代了分钟级的直接建模。

通过构造正弦及余弦形式的 Fourier 特征作为模型输入来刻画液位时间序列的日周期变化，在保证较大的周期信息的前提下减少了模型的计算复杂度，得到较好的预测效果以及较高的计算效率。

对于模型的训练，在模型训练阶段采用历史液位序列及对应外生变量估计 SARIMAX 模型参数；预测阶段根据未来的时间段外生变量实现液位的多步预测。从实验可知，此模型预测效果较平滑，稳定性与可解释性强，因此可以将此模型作为液位预测的一个基准模型。

（2）基于 LightGBM 的机器学习预测模型

除了利用传统的时序模型方法之外，本章还构建了基于 LightGBM 机器学习预测模型，用以刻画液位变化和历史液位、气象变量之间的非线性关系。LightGBM 是梯度提升决策树的一种实现方式，既可以满足多维特征输入情况下较高的计算效率要求，也可以完成较强的非线性拟合。

在特征构建方面，除了模型输入中加入了气象变量之外，同时加入了诸多历史液位的滞后项及滚动统计项作为特征输入，用来刻画液位的短时与中长时的记忆关系，并利用时间索引构造了小时、星期、月份的时间类特征来辅助模型更好的发现液位在不同时次的变化规律。

本文的预测方法为递推式多步预测，即通过更新上一时刻的历史序列来改进本次预测的结果，以此来对下一个时刻的液位值进行预测。虽然这样的方法能提高预测的精度，但是方法的稳定性还要做进一步实验探究。

（3）模型设置与对比原则

为保证不同模型之间比较的公平性，本文对 SARIMAX 和 LightGBM 模型采用相同的训练区间和预测区间，并基于统一的数据预处理结果进行建模。模型性能主要从以下三个方面进行评估：

预测准确性方面，通过均方根误差（RMSE）和平均绝对误差（MAE）衡量预测结果与真实液位之间的偏差；

计算效率方面，记录模型训练和预测所需的时间，用于比较不同模型的计算成本；

根据预测曲线的平滑性、稳定性和与实际变化趋势一致的程度，对模型输出的结果可靠性进行定性分析。 利用本文所提出的多维评价体系，对比分析了传统的时间序列模型与机器学习模型针对液位预测的性能。

（4）小结

本节分别构建了基于 Fourier－SARIMAX 的传统时间序列模型和基于 LightGBM 的机器学习模型，为管网液位短期预测提供了两类具有代表性的建模方案。两种模型在建模思路、特征表达能力以及预测特性方面存在明显差异，为后续的结果分析和模型性能比较奠定了基础。

3.3 异常识别方法

针对管网液位异常识别问题，本文严格遵循题目中对异常数据的定义，将异常界定为不符合历史昼夜节律特征的液位变化。异常识别方法以液位对正常昼夜节律的偏离程度作为主要判据，并结合同期降雨信息对识别结果进行辅助分析，以提高结果的合理性和可信性。

（1）正常昼夜节律参考模式的构建

为了表示管网液位运行情况下的液位变化规律，采用 2022 年 10 月 20 日～11 月 10 日这一时期内管网实际运行数据为研究样本区间。此时管网处于正常运行状态，且在该期间管网内各项参数波动较小，基本符合液位变化情况在日尺度上呈现的典型特点。

按在参考区间内利用一天的时机位置将所涉及的液位数据按时间分组并统计出不同时间段所对应的液位特征，以此为基础建立液位正常昼夜节律的参考模式，以描述一天之内液位沿时间演变情况的平均值作为模型输入，为后续的异常判定提供参考依据。

（2）基于节律偏离的异常判定方法

通过构建昼夜节律参考模式，在此基础上取 2023 年 1 月 1 日—2023 年 2 月 1 日为检测区间，按照从检测区间的某一天当中任意时刻开始循环的形式向后遍历一段时间，将实际监测到的液位值与对应的节律参考值相比较，得到二者之间的偏离程度。

液位观测值偏大的时间点，与正常昼夜节律特征的偏差达到显著程度，即该时间点被认定为异常。这种方法可以识别出一些不是数值特别大，但是从时间结构上已经完全不是正常的昼夜变化规律的液位行为，其结论也符合题目的异常判断标准。

（3）降雨信息的辅助分析作用

由于降雨会造成液位合理波动，故本论文结合同期降雨数据对异常识别结果进行补充性解释分析，但降雨并没有作为判别阈值的一部分参与异常判断，仅能起到说明原因的作用。

如果某个时期液位存在较大程度的偏离昼夜节律且没有明显降雨，则此时异常更有可能是在管网运行过程中产生的异常；反之，如果某段时间液位偏离了昼夜节律，并且出现了较大的降雨过程，则有必要考虑降雨因素对液体位的影响。基于雨水情况的辅助判定可以减少系统将正常的环境响应误判为异常的风险。

（4）方法说明

应该注意到，在本文的异常识别过程中，并没有使用真实异常标签，所以在定量上无法用分类准确率评价，所以异常识别的结果主要是通过异常时间序列可视化和异常出现的时间分布特征，以及其和降水过程的关系进行说明和解释。

总体而言，本文用昼夜节律偏移作为异常识别标准，该方法简单直接且易解释，而且计算成本较小，适用于长时间序列管网液位的异常检测。

3.4 多变量预测模型

基于 inflow、loading 与 obs 的数据，本文构建比较了不同的机器学习模型，并对各建模方法的预测精度、计算速度以及结果稳定性的优缺点进行对比说明，任务属于多输出回归问题，即同时需要预测多个被观测值，因此对于模型的表达能力以及计算能力均有所要求。

（1）线性基线模型

为了提供对比基准，本文基于这两种不同的训练方式分别搭建了一类为 Ridge 回归以及一类为 ElasticNet 回归的线性模型。线性模型的模型结构较为简单，计算速度也较快，可作为多变量预测问题中的基础方法进行使用。

Ridge 回归加入 L2 正则化项限制模型复杂度，从一定程度上避免了因输入变量过多造成多变量共线性；ElasticNet 回归既利用 L1 实现模型的稀疏性稳定性能较好，也利用 L2 限制模型过拟合，能有效降低冗余特征对预测结果的影响。两者都是对输入特征进行标准化处理过的线性模型，在其建立过程中都做足了对输入变量的处理，使变量处于同一数量级之中。

（2）基于 Boosting 的非线性模型

以刻画 inflow、loading 和 obs 之间的非线性关系为目的，在此基础上采用基于 Boosting 思想的非线性模型，包含 Histogram-based Gradient Boosting(HGBoost)和 LightGBM 模型。

Histogram-based Gradient Boosting 通过直方图近似的方式来近似连续特征，因此计算开销较小，适于较大规模的数据集；LightGBM 是基于 GBDT 算法的基础上融合了更高效地特征分裂算法与并行化的思想，在保证一定预测准确性的前提下，使得计算速度更快，适用于 GBDT 类模型训练与预测的加速；以上两种模型都采用了多输出回归框架，实现了对每个观测变量同时预测。

（3）基于随机树的集成模型（ExtraTrees）

除了 Boosting 模型外，本文还基于随机树集成建立了一个 ExtraTrees 回归模型作为对比方法。最初本文打算用随机森林模型来做多输出预测，但随机森林在多输出情况下训练时间较长、计算成本较高，不适合做多个模型的系统比较，故选择在 RFE_17 个相关的初始变量输入的基础上来进行多输出建模实验。

考虑到以上问题，在这里选择结构与随机森林相似，但是再进行节点分裂时加入更多的随机性的 ExtraTrees 模型代替。由于减少最优切分点的搜索过程，降低了大量无用计算，因此相比于单纯采用 RF 模型更能在短时间内进行模型的构建，在预测效果相对接近的情况下更为适合多模型对比与效率评估使用。

（4）小结

本节建立了模型并将其进行对比，分别为线性模型、Boosting 类型的非线性模型、基于随机树的集成模型。不同的模型在拟合精度上、计算速度上、拟合结果稳定性上有各自的优缺点，这为后续 obs 异常高值原因识别模型的搭建提供了一些思路和经验。

3.5 原因识别方法

基于完成多变量预测模型的过程，在此阶段对观测变量 obs 异常高值原因进行识别分析：以某一时刻的 obs 数值最高为切入点，分析该 obs 数值最高点最有可能被哪几个 inflow、loading 采集点的高值数据驱动所影响，得出观测变量 obs 的异常成因解释。

（1）回归模型的选择与建模

在原因识别阶段使用梯度提升树回归模型来建立 obs 变量的预测模型。该模型是因为之前文中已经做过各种模型之间的比较，而且本题中多个变量组合情况下此模型具有更好的预测精度以及更高的计算效率。其它模型的具体比较情况会在结果分析部分进一步介绍。

实现中，模型将所有 inflow 和 loading 变量作为输入，并使用当前分析的 obs 变量作为目标变量进行训练，给后续基于模型的解释分析打下基础。

（2）相对高值样本的定义

为了避免使用给定绝对阈值去定义观测的高值，本文将采用分位数方法定义观测的相对高值：当观测值大于历史分布对应的高分位数（例如：大于 95%分位数时）则认为该观测是相对高值。

针对单一 obs 变量，可以采用适合于不同观测变量尺度定义阈值的方法进行原因识别分析，并且还能保证识别出的数据是真正意义上具有代表性、发生极端行为的不正常值，同时能较好地避免部分分析结果中受少量极值的影响过大。

（3）基于 SHAP 的模型解释方法

识别出相对高值样本之后，在本文利用 SHAP 方法对梯度提升树模型的预测结果进行解释。由于 SHAP 方法能够在一个样本层面定量地反映各个输入特征对模型输出的影响程度，是一种比较适合于为复杂回归模型给出合理的、具有一致性和可解释性较强的解释的结果的方法，故本文选取了该方法对所得结果进行解释说明。

通过部分样本来做背景数据的方式，在保证 SHAP 的解释性的同时加快 SHAP 计算的过程，达到既减小计算量又保证解释效果的目的。

（4）按采集点位的贡献聚合与主因识别

这里需要说明的一点是：由于 inflow 和 loading 是同一个采集点所获取的数据，故在本文的解释阶段将其对应 inflow_k、loading_k 的 SHAP 贡献值合并成一个，作为该采集点（第 k 个）对 obs 的总体贡献。

对于每一个相对高值样本，本文比较不同采集点的合并贡献值，并将贡献最大的采集点视为该样本中 obs 高值的主要驱动因素。进一步对所有高值样本的识别结果进行统计，计算各采集点在高值样本中成为主要原因的出现频率，从而在整体意义上识别最可能导致 obs 高值的 inflow－loading 组合。

（5）多 obs 的统一分析

上述原因识别流程对所有 obs 变量分别执行，并对结果进行统一汇总。对于每一个 obs，本文记录其相对高值阈值、最可能的 inflow－loading 组合，以及该组合在高值样本中出现的频率，为后续结果分析和不同 obs 变量之间的对比提供结构化输出。

4.算法结果与准确性分析

4.1 液位预测准确性

相对于其他仅利用时间序列分析的建模方法，采用本文提出的结合 Fourier-SARIMAX 模型与 LightGBM 机器学习方法用于管网液位预测相比传统的纯时间序列建模效果更好，在预测区间内模型的预测表现更佳。以 2022 年 10 月 1 日～2022 年 11 月 11 日

为模型训练时间区间，以 2022 年 11 月 11 日～2022 年 12 月 1 日为预测区间进行液位变化预测。

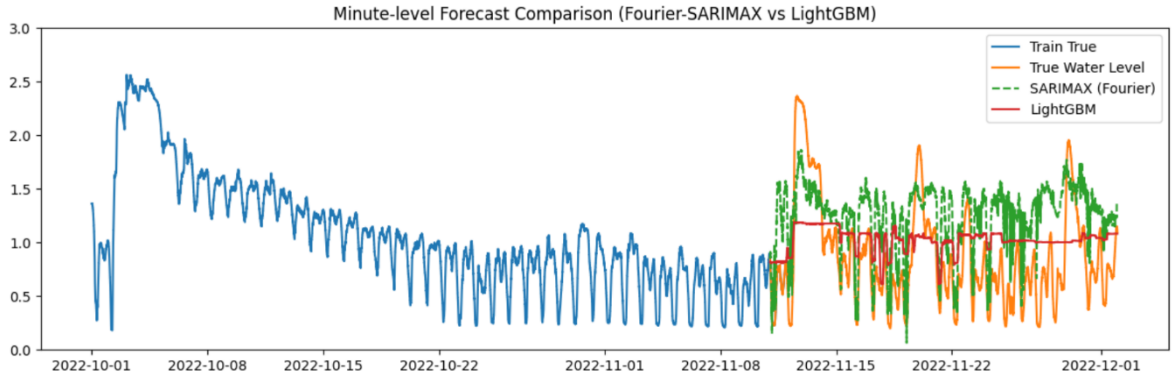


图 4.1

图 4.1 给出了两种模型在预测区间内液位值的真实值以及预测值之间的比较。由图可知，两种模型都较好地跟随了液位的主要变化趋势，说明两个模型在刻画液位整体变化的趋势上有一定的意义，在局部振幅与数值拟合程度上还是有所不同的。

由定量评价的结果可知，LightGBM 的预测准确性高于 Fourier－SARIMAX 模型，其平均绝对误差（MAE）、均方根误差（RMSE）分别为 0. 385 和 0. 458；而 Fourier－SARIMAX 模型的 MAE、RMSE 分别为 0. 481、0. 538，因此在区间预测时，LightGBM 在整个误差范围内的预测效果略好于 Fourier－SARIMAX 模型。

除去一些传统的误差指标，我们又从预测序列的统计特性角度来分析，发现在平均漂移程度上，LightGBM 模型的预测序列低于 Fourier－SARIMAX,其预测均值和真实液位均值之间的差也相对较小，因而说明 LightGBM 模型能更好地拟合出长期平均水平。再者，在整个预测区间里 LightGBM 的预测波动率整体低于 Fourier－SARIMAX,可见该模型的结果比较平稳。

需要指出的是，LightGBM 相比而言对局部突变的刻画能力更高，而所具有的尖峰比例略高也说明了这一点，这是由于对于短期内的变化更加敏感，因而可以及时反应出局部的波动，但由于短期中的不稳定性导致预测误差变大造成的。

如上文分析可知，两个模型在液位预测上的预测性能不一样：Fourier-SARIMAX 项下的预测结果比较平滑，更能体现液位的周期特性；而 LightGBM 有整体误差小、误差平均值拟合程度较好等特点，但在个别时间段的波动强度更大一些。对于后续研究模型稳定性与可靠性有参考意义。

4.2 异常识别结果

通过对前文给出的昼夜节律偏离检测方法，对 2023 年 1 月 1 日至 2023 年 2 月 1 日的管网液位数据进行了异常识别分析，并得到图 4.2 所示的检测区间内液位的时间序列，以及判定为异常的时间点。图 4.2 液位时间序列及检测结果判别时间点

如图所示，在检测区间内液位一直存在较为明显的日周期波动规律性现象，表明大多数时候管网运行都有稳定的工作节律状态；但是在有少部分时间段内，液位的变化却与之前的历史参考区间的昼夜节律正常波动有所不同，因此属于异常情况。

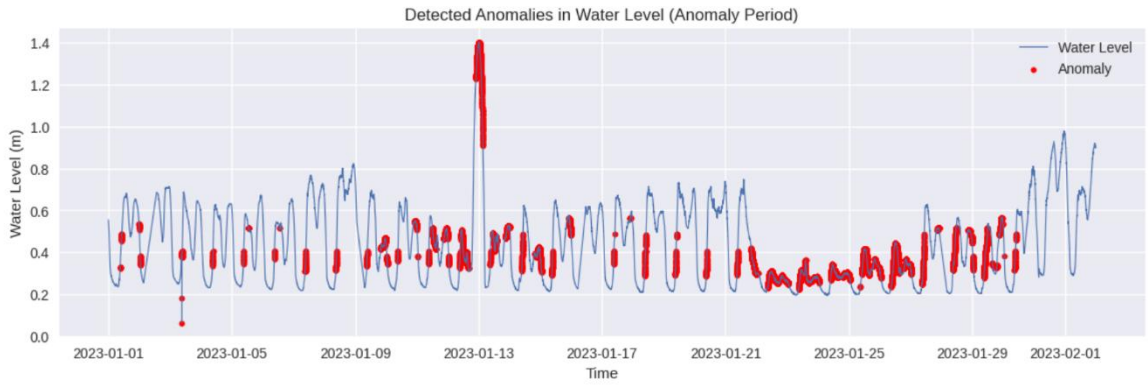


图 4.2

2023 年 1 月上旬出现一段短时间内液位值突然上升较大的波动期，异常出现在图中表现为一段时间内的大量离群值点，异动程度大，并且不规则、不受控，即明显的突发型异常。

此外，除了极少数情况存在极端异常外，在其它各个时间点上还有少量的分散异常点出现，而这类异常一般不存在很大的数值型偏差，但是却能反映出液位的变化规律存在一定的异常，如振幅异常、相位偏移等现象，也就是液位变化的节奏和正常情况下的昼夜变化有所偏离，属于题干所提到的异常的数据形式。

从异常数量的统计结果来看，在采用较严格判定条件时，被识别为异常的数据点数量为 7 306 个，约占检测区间样本总数的 17.9%。在相对宽松的判定条件下，异常点数量为 7 319 个，其比例与严格条件下的结果接近。两种判定方式下异常数量差异较小，说明所采用的昼夜节律偏离检测方法在异常识别结果上具有较好的稳定性。

由综合异常点分布形态与数量统计结果可知，本文所提出的异常识别方法可准确判断不属于历史正常昼夜节律液位异常行为，既能识别出液位的突发型异常点，又能识别出节律偏离型异常点，可为后期的异常原因分析及模型可靠性讨论提供一定的依据。

4.3 多变量预测准确性

多变量预测任务方面比较各种机器学习模型在分别用相同的自变量集合预测 obs1～obs12 的基础上，观测结果的预测性能评估指标以测试集上的均值预测误差来衡量，其具体包括用以表征模型误差水平高低的 AVG_RMSE 以及用于表征模型拟合观测变量变动情况的 AVG_R^2 。

表 4.3 不同模型多变量预测准确度的对比情况，可以看出，在各类模型中以基于 Boosting 思想的模型性能最优异；另外基于 Histogram 的 GBRT 模型和 LightGBM 模型最为接近，两者的平均 RMSE 值为 1．912 和 1．913，对应均值的平均 R_2 值均约

为 0．63，这说明这种类型的模型可以较好地体现 inflow 和 loading 共同作用下对 obs 变量的影响。注：对比结果是基于所有 18 个测试集的数据得到的结果。

```
===== Model Comparison =====
                  Model  TrainTime(s)  PredTime(s)  AVG_RMSE    AVG_R2
2  HistGradientBoosting     36.664877     7.486769  1.912352  0.633830
3              LightGBM     33.894898     5.044547  1.912793  0.633594
4            ExtraTrees     30.907365     0.677680  2.146870  0.535912
0                 Ridge      0.265749     0.015438  2.325613  0.484135
1            ElasticNet      2.039379     0.014720  2.359598  0.466496
```

表 4.3

相比之下， ExtraTrees 模型的预测准确度低于 Boosting 类模型，其平均 RMSE 和平均 R2 分别为 2.147、0.536，虽然这个模型较梯度提升类模型在整体上不会把预测误差压制得那么低，但是依然优于线性模型，故基于树结构的非线性方法对于这类问题而言是一个相对较好的办法。

虽然使用线性模型（Ridge 和 ElasticNet）有一定的准确率，但是并不能说较好，由于需要拟合线性模型，平均 RMSE 都超过了 2.3，而平均 R^2 也都低于 0.5，表明对于 inflow、loading 以及 obs 之间的这种映射关系并不是单纯依靠线性就可以进行解释清楚的。因此可以发现，在多变量预测任务中并不全是线性的，这样用非线性的模型会更好一些。

综上可知，在多变量的预测准确性方面，梯度提升类模型优于其他类型的模型，且各观测变量的预测精度相对较高、稳定，从而可以提供可靠的基础来完成后续的 obs 异常高值原因识别分析。

4.4 原因识别结果

基于上文提出的异常原因识别方法，分别讨论了 obs1-obs12 观测变量在产生相对高值时的主要驱动因子，并且展示了图 4.4，图中描述了除 obs1 以外的所有观测变量在高值样本集中，不同 inflow-loading 的出现频次。

由总体结果可以看出，各 obs 变量对应的主要驱动采集点有所不同；另外，大部分 obs 的高值行为可由少量的采集点来实现，说明 inflow 与 loading 的空间分布对观测

变量的影响是不均一的。

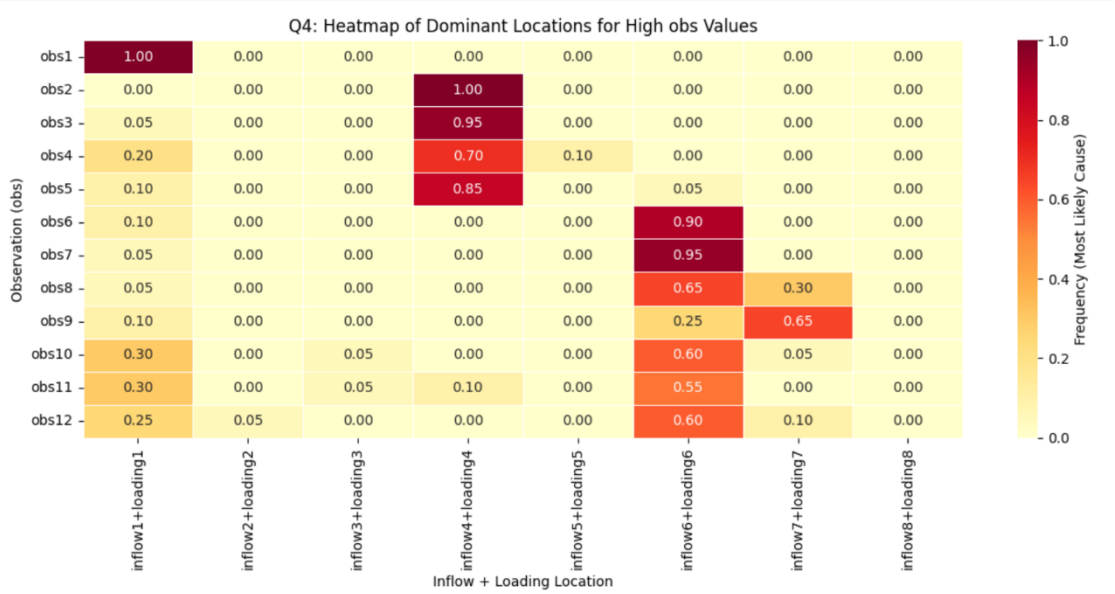


图 4.4

具体来说，obs1 高的原因主要是因为 inflow1+loading1 采样点引起的，所以该采样点对于 obs1 的影响是很大的；obs2、obs3、obs4、obs5 高的原因都是由于 inflow4+loading4 采样点引起的，在 obs3 和 obs5 这个采样点所起的作用都是起主导作用的。

对于 obs6、obs7 来说，两者的高值行为主要是由 inflow6+loading6 导致，两者的高值行为频率分别为 90%、95%，说明两组观测值的异常高值源相对比较集中；而对于 obs8、obs9 来说，两者的高值行为具有一定的多源特性，在高值样本中有较多一部分是由 inflow6+loading6 和 inflow7+loading7 造成的，因此也体现出频率分别为 27.4%、21.7%。

但是从 Obs10～Obs12 测点的数据来看，流入项 inflow6+loading6 还是更为主要的因素，但是 Obs10～Obs12 的相邻采集点 inflow1+loading1 等的影响也有所加大。即说明此时阶段，观测变量高值是受影响于多个采集点的共同作用所致。

另外，在原因识别时，本文将原因识别单元设为“采集点”，即将同采集点下的 inflow 和 loading 变量作为一个整体进行原因识别，并不区分其是否来自不同的流量监测站；考虑到题目对数据采集方式的描述，故这种处理方式也是合理的，能够保证原因识别结果具有可解释性及物理合理性。

从原因识别结果看，在不同的观测变量处于高值时段时，占主导地位的采集点是与之密切相关的，因此可以根据原因识别结果选出相应的采集点作为重点，有针对性地开展监测和管理。

5.算法效率与可靠性分析

本章从算法运行效率和结果可靠性两个方面，对前文所采用的方法进行了综合分析。本文在预测类任务中重点比较不同模型的计算效率和预测稳定性；在异常识别与原因识别任务中，本文主要关注方法本身的稳定性和结果一致性。

本文把分钟级液位预测任务分别用到 Fourier 特征的 SARIMAX 模型和 LightGBM 模型，通过实验得知 SARIMAX 模型的训练用时为 231.6 秒，LightGBM 模型的训练用时为 11.6 秒，由此可见，二者训练速度差别较大；从预测角度看，两种模型的运行时长都满足秒级的要求，符合实际需求。

为更好分析模型预测结果，本章选择预测波动率、尖峰比例和均值漂移三个指标对模型输出的结果做进一步对比研究。从图 4.1 的结果可知：LightGBM 模型在预测波动率和均值漂移方面的预测效果均不如 SARIMAX 模型好，但相比 SARIMAX 模型而言，其预测均值与真实观测均值的差距比较小；另外，SARIMAX 模型的尖峰比例稍低一点，说明该模型对于局部短期变化具有一定的刻画能力。

本节对比了几种不同类型的机器学习模型在多变量预测任务上计算时间和预测精度上的差异。可以看到，无论是从训练上还是从预测上，线性模型（Ridge 和 ElasticNet）的速度都是最快的，但是预测准确度也是最低的；ExtraTrees 在预测时所花费的时间非常少，但是在一些观测变量上可能存在一些系统性的偏差；相比之下，梯度提升类的模型虽然需要花费更长时间来训练模型，但是在准确度方面仍旧拥有优势，并且还能维持较高的效率，在效率与性能上取得了较好的平衡。

就多变量预测结果而言，模型在梯度提升类模型对大多数 obs 变量的走势都比较符合实际的变化情况，在拐点及波动区间都较为一致（如图 5）；但是相较于线性模型对所有变量波动幅度被严重低估的情况以及 ExtraTrees 模型的偏移情况来说，梯度提升类模型还是更好的选择。

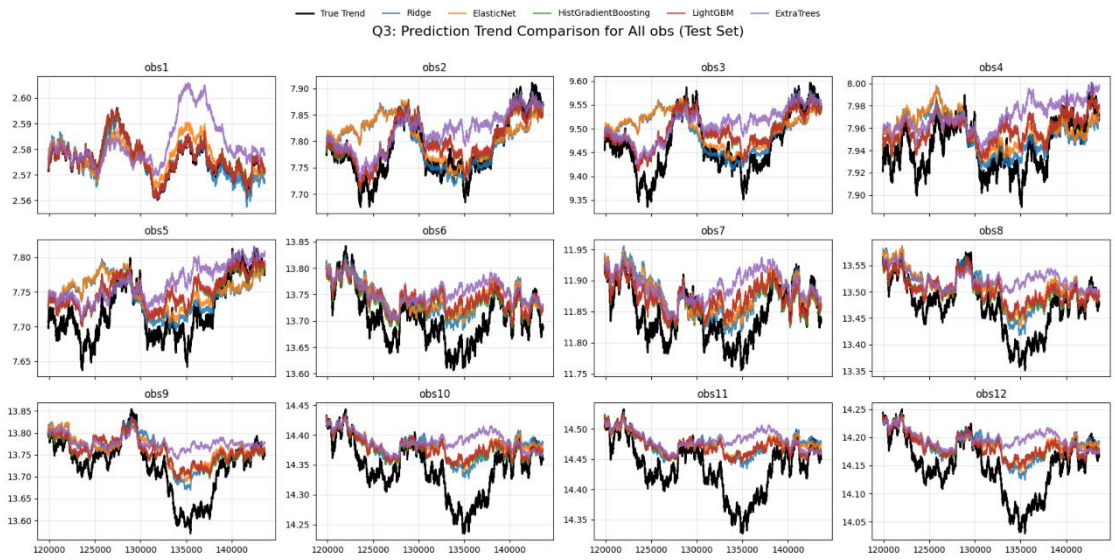


图 5

在异常识别任务中，本文基于昼夜节律偏离的方法对异常结果进行了稳定性分析。分析结果表明，被识别为异常的数据主要集中在明显偏离正常周期结构或出现突发尖峰的时间段。异常点在检测区间内所占比例较低，且在引入连续异常点筛选后，本文进一步减少了零散噪声点，说明该方法在异常敏感性与稳定性之间取得了较好平衡。

本文使用分位数定义观测变量的高值事件，并利用梯度提升模型和 SHAP 解释方法开展原因识别研究，结果发现多数 obs 变量高值阶段的主要采集点在多次事件中存在重复现象，说明原因识别结果具有一定的稳定性及可重复性。

总体而言，本文结果表明各类方法运行效率及结果的可靠性均较好，可以对前文预测分析结果、异常识别结果、原因解释结果提供有力支撑。

6.模型性能比较与讨论

本章在前述实验结果与效率分析的基础上，对不同建模方法在本研究场景下的整体表现进行归纳和讨论。与结果章节不同，本文不再重复具体实验指标，而是从方法特性、任务适配性以及分析流程完整性等角度，总结不同模型在管网数据分析中的适用性与局限。

本研究的结果表明管网液位预测、多变量预测具有较强的非线性特征及潜在的交互结构，因此模型要获得理想的预测效果就必须要能自动地刻画出模型输入之间的非线性关系。这也说明了线性模型虽然计算高效，但是无法刻画出输入变量间的非线性关系，所以无论模型能拟合什么程度的线性趋势，都无法适应于该类问题下的预测需求。

相比之下，基于树结构的模型可以在不需要人为设定函数形式的前提下自动学习不同变量间的复杂关联，在处理多输入多输出问题时更加容易去适配任务本身的特点；基于梯度提升类模型可以较好的完成预测、异常分析与原因识别等多个任务，由此可知其不但可以解决单一预测问题，同时也有利于完成整个数据流全链条的数据分析工作。

液位预测任务中，有传统的时间序列模型，也有机器学习模型。两种模型分别代表了不同的建模思想。传统时序模型因为有确定性的解释而优势在于建模周期结构，但是它们在高频率、多变量条件下会有计算量大、建模不够灵活的问题；而机器学习模型通过引入外生信息以及历史依赖性特征来兼顾效率和稳定性的特点，使其更加具有工程实用性。

此外，进一步分析发现，仅依靠预测误差很难全面准确地反映系统的运行状态，将基于结构特征的异常识别和预测结合起来，从导致预测失效的原因入手，进行详细分

析，更加有利于对造成故障的原因进行准确定位，以及提高综合分析的结果解释度。“预测—异常—解释”的思路在管网监测数据分析中也是一条比较好的实践路径。

可以注意到本文的模型还存在一些局限性：模型中没有把各采集点的变量之间相互作用关系明确表现出来，参数也是通过经验的方法得到的结果；另外本文的研究结论是基于某一时刻进行分析而得到的结果，在不同的运行情况下是否能适应还需进一步检验模型在变化情况下的泛化性能。

总体而言，上述研究发现，在频率高、变量多的管网数据分析任务下，模型需要有非线性的建模能力且便于解释，把机器学习的方法作为综合分析框架的核心更为合适。

7.结论

基于管网液位和多变量观测数据，在进行预测建模、异常识别和原因分析等方面构建了一个综合分析流程，并进行验证。不是从模型角度来看待其中某一种方法优于另一种方法，而是着眼于各种方法如何更好地适用于高频度、多变量管网数据这一方面考虑。

研究发现，与多种高频时间序列、多源外生变量相关的预测问题中，对于非线性及潜在交互结构刻画能力是否足够强决定了模型的分析效果，而非基于确定的函数形式来建立模型，而是可以根据模型自身学习的结果来不断调整自己的参数，则模型本身所能够得到的预测稳定性更好、总体的一致性更强，这对于高频管网数据建模方法的选择有着重要的指导意义。

深入挖掘后我们得知，单靠预测的结果并不能了解整个系统的运行状态。异常检测的方法可以区分开由于异常导致的局部突发变化和系统的结构性偏离情况，并且可以给人们探索预测误差产生原因时提供帮助。采用基于历史运行模式约束来定义异常的方式，在保证了结果稳定的同时也提高了分析的过程的可解释性。

除了这些基于已有研究成果的推测之外，借助原因识别也可以减小二者间的差异，即解释异常或高值时段的具体驱动因素，在各个观测点中找寻决定性的采集点，进而发现系统的空间异质性，因此解释分析部分不仅仅只是对预测结果的解释说明，也是整个分析流程的重要一环。

总体而言，该项研究的结果表明，通过将预测分析、异常检测和原因分析相结合来描述管网系统特性是从不同的层面对管网系统进行运行特性刻画的有效方法。此种基于非线性建模并基于结构理解的分析方法有利于提高高频、多变量工程数据的可靠性以及应用价值。

基于该方法的基础，未来可以考虑进一步扩充方法，比如使用更多长时间数据来检验分析流程的稳健性；通过探究不同采集点变量之间的交叉作用，刻画更深层次的驱动机制；或者结合预测和异常，形成更为前瞻的预警框架。

References

[1] Ke, G., et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems, 2017.

[2] Lundberg, S. M., & Lee, S.-I. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems, 2017.

[3] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. Time Series Analysis: Forecasting and Control. Wiley.